

DOCUMENTAÇÃO TÉCNICA

Laboratório de Macroeconometria

Fundamentos teóricos, recursos e arquitetura

Aplicação interativa para análise de séries
macroeconômicas brasileiras

Streamlit · statsmodels · scikit-learn

SUMÁRIO

1. Propósito e visão geral

- 1.1 O problema que o aplicativo resolve
- 1.2 Fluxo de trabalho recomendado
- 1.3 A restrição amostral

2. Preparação dos dados

- 2.1 Exploração e cobertura
- 2.2 Transformações disponíveis
- 2.3 Construção de spreads

3. Estacionariedade

- 3.1 O problema da regressão espúria
- 3.2 Teste ADF
- 3.3 Teste KPSS e o diagnóstico cruzado
- 3.4 Ordem de integração

4. Regressão linear

- 4.1 Especificação e estimação
- 4.2 Erros-padrão robustos
- 4.3 Diagnósticos de resíduos
- 4.4 Multicolinearidade
- 4.5 Validação fora da amostra

5. Cointegração

- 5.1 Conceito e intuição
- 5.2 Engle-Granger
- 5.3 Johansen

6. Modelos vetoriais

- 6.1 VAR: motivação
- 6.2 Seleção de ordem
- 6.3 Funções de resposta a impulso
- 6.4 Identificação estrutural
- 6.5 Decomposição da variância
- 6.6 Causalidade de Granger
- 6.7 VECM

7. Modelos de resposta binária

- 7.1 Probit e Logit
- 7.2 Previsão de recessão
- 7.3 Avaliação por AUC

8. Regularização

- 8.1 Motivação
- 8.2 LASSO, Ridge e Elastic Net
- 8.3 Colinearidade e instabilidade
- 8.4 Stability selection
- 8.5 Limites interpretativos

9. Modelos macroeconômicos aplicáveis

- 9.1 Transmissão de política monetária

- 9.2 Curva de Phillips
- 9.3 Regra de Taylor
- 9.4 Ciclos de crédito
- 9.5 Previsão de recessão

10. Arquitetura do código

- 10.1 Separação em camadas
- 10.2 `core.py`
- 10.3 `modelos.py`
- 10.4 `app.py`
- 10.5 `manual.py`
- 10.6 Decisões de projeto

11. Limitações e extensões

1 Propósito e visão geral

1.1 O problema que o aplicativo resolve

A análise macroeconométrica aplicada envolve uma sequência de decisões interdependentes: qual transformação aplicar a cada série, se as séries são estacionárias, se compartilham tendências comuns, qual modelo é adequado dado esse diagnóstico e como interpretar os resultados. Cada uma dessas decisões condiciona as seguintes, e um erro nas etapas iniciais propaga-se silenciosamente até conclusões substantivas.

O ciclo convencional de trabalho — escrever um script, executá-lo, inspecionar a saída, editar o script — é lento para exploração. Testar dez especificações alternativas significa dez edições manuais. O custo cognitivo dessa repetição desestimula precisamente a verificação de robustez que a boa prática exige.

Este laboratório inverte essa lógica. A escolha de variáveis, transformações, períodos e parâmetros é feita por controles interativos; a estimação e os diagnósticos são executados imediatamente. O objetivo é reduzir o custo marginal de testar uma especificação alternativa a praticamente zero, tornando viável a exploração sistemática que a inferência confiável requer.

Princípio orientador. Cada resultado é acompanhado da equação de referência, dos testes de diagnóstico pertinentes e de notas de interpretação. A ferramenta não busca apenas produzir números, mas explicitar o que os números significam e sob quais condições são válidos.

1.2 Fluxo de trabalho recomendado

A ordem das etapas não é convenção arbitrária: cada uma é pré-requisito estatístico da seguinte.

- [1] Explorar → identificar cobertura temporal e gargalo amostral
- [2] Transformar → induzir estacionariedade
- [3] Testar → confirmar via ADF e KPSS
- [4] Diagnosticar → $I(0)$? $I(1)$? cointegradas?
- [5] Modelar → escolher o modelo compatível com o diagnóstico
- [6] Validar → resíduos, estabilidade, desempenho fora da amostra

A etapa 4 determina a 5 de forma quase mecânica:

Diagnóstico	Modelo indicado	Justificativa
Todas $I(0)$	Regressão, VAR	Inferência assintótica padrão é válida
$I(1)$ sem cointegração	VAR em diferenças	Diferenciar induz estacionariedade
$I(1)$ com cointegração	VECM	Diferenciar destruiria a relação de longo prazo
Dependente binária	Probit / Logit	MQO produziria probabilidades fora de $[0,1]$
$p \gg n$ ou colinearidade	Elastic Net	Regularização estabiliza a estimação

1.3 A restrição amostral

Em bases macroeconômicas, séries diferentes começam em datas diferentes. A amostra efetiva de um modelo multivariado é a interseção das séries incluídas — determinada, portanto, pela série mais curta. Uma base cuja taxa básica de juros remonta a 1974 mas cuja estrutura a termo começa em 2015 oferece, para qualquer modelo que use ambas, apenas o período posterior a 2015.

Essa restrição tem consequência direta sobre a complexidade admissível. A regra prática para modelos vetoriais exige aproximadamente dez observações por parâmetro estimado. Um VAR com quatro variáveis e seis defasagens

estima cerca de cem coeficientes, requerendo em torno de mil observações — inviável em séries mensais de uma década. Sistemas de três a quatro variáveis com duas a quatro defasagens são o limite realista.

Sintoma de sobreajuste. Um VAR com raízes características próximas ou superiores à unidade em amostra curta indica que o modelo está ajustando ruído. O aplicativo verifica a estabilidade automaticamente e sinaliza quando isso ocorre.

2 Preparação dos dados

2.1 Exploração e cobertura

A primeira aba apresenta, para cada variável, o número de observações válidas, as datas inicial e final, estatísticas descritivas e o percentual de valores ausentes. A coluna de data inicial identifica imediatamente o gargalo amostral de qualquer combinação pretendida.

A matriz de correlação complementa esse diagnóstico. Correlações superiores a 0,9 entre regressores candidatos antecipam problemas de multicolinearidade — situação típica entre vértices vizinhos de uma curva de juros, cujas taxas de prazos próximos movem-se quase em conjunto.

2.2 Transformações disponíveis

A escolha da transformação deve refletir a natureza da série e o conceito econômico de interesse.

Transformação	Expressão	Aplicação típica
Primeira diferença	$\Delta y = y_t - y_{t-1}$	Taxas em nível (juros, desemprego)
Log-diferença	$[\ln y_t - \ln y_{t-1}] \times 100$	Índices e volumes: variação percentual
Log-diferença 12m	$[\ln y_t - \ln y_{t-12}] \times 100$	Variação anual; atenua sazonalidade
Soma móvel 12m	$\sum y_{t-i}, i = 0 \dots 11$	Acumular taxas mensais (inflação em 12 meses)
Filtro HP (ciclo)	$y_t - \tau_t$	Extração de hiato do produto
Padronização	$(y - \mu) / \sigma$	Pré-requisito para regularização

A log-diferença merece nota. Para variações pequenas, ela aproxima a taxa de crescimento percentual, com a vantagem de ser aditiva ao longo do tempo — a soma das variações mensais equivale à variação do período. Séries que crescem de forma multiplicativa, como agregados monetários e de crédito, tornam-se aproximadamente lineares em logaritmo, o que estabiliza a variância.

O filtro Hodrick-Prescott decompõe a série em tendência e ciclo minimizando uma soma ponderada entre o desvio da tendência e a variação da própria tendência, com parâmetro de suavização λ . Para dados mensais, o valor convencional é $\lambda = 14.400$.

Ressalva sobre o filtro HP. A literatura registra críticas substantivas ao seu uso, notadamente a geração de dinâmicas espúrias e a instabilidade das estimativas nas extremidades da amostra — precisamente onde o interesse costuma ser maior. Interprete o hiato extraído com cautela, sobretudo em observações recentes.

2.3 Construção de spreads

Quando um conjunto de variáveis representa pontos de uma mesma estrutura — como os vértices de uma curva de juros — incluí-las simultaneamente em uma regressão gera colinearidade severa. A alternativa é construir o objeto economicamente relevante: a inclinação.

$$\text{spread}_t = i_t^{(\text{longo})} - i_t^{(\text{curto})}$$

A inclinação sintetiza a estrutura a termo em uma única variável interpretável, eliminando a redundância entre vértices adjacentes.

A inclinação da curva de juros é, além disso, um dos preditores de recessão mais robustos documentados na literatura empírica, o que confere ao spread motivação teórica além da conveniência estatística.

3 Estacionariedade

3.1 O problema da regressão espúria

Uma série é estacionária em sentido fraco quando sua média, variância e autocovariâncias não dependem do tempo. A relevância prática desse conceito decorre de um resultado clássico: a regressão entre duas séries não-estacionárias independentes tende a produzir coeficientes aparentemente significativos e coeficiente de determinação elevado, mesmo na ausência completa de relação.

O mecanismo é intuitivo. Duas séries com tendência ascendente exibirão correlação alta simplesmente porque ambas crescem, independentemente de qualquer vínculo econômico. A estatística t convencional não converge para a distribuição normal nesse contexto, e os valores críticos usuais deixam de ser válidos.

Implicação. Coeficiente de determinação elevado combinado com estatística de Durbin-Watson próxima de zero é o sintoma clássico de regressão espúria. O diagnóstico correto exige testar estacionariedade antes de estimar, não depois.

3.2 Teste ADF

O teste de Dickey-Fuller aumentado avalia a presença de raiz unitária. A regressão auxiliar é:

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{i=1}^p \delta_i \Delta y_{t-i} + \varepsilon_t$$

A hipótese nula é $\gamma = 0$, correspondendo à presença de raiz unitária. Os termos em diferença defasada corrigem autocorrelação residual — daí o qualificativo "aumentado".

Rejeitar a nula indica estacionariedade. A especificação determinística importa: incluir constante e tendência quando a série exibe tendência determinística evita conclusão incorreta de não-estacionariedade.

3.3 Teste KPSS e o diagnóstico cruzado

O teste KPSS inverte a hipótese nula: postula estacionariedade e testa contra a alternativa de raiz unitária. Essa inversão não é redundância, mas complemento. Testes de raiz unitária têm poder reduzido em amostras curtas — a não-rejeição da nula do ADF pode refletir ausência de evidência, não evidência de ausência.

Aplicar ambos permite quatro configurações:

ADF	KPSS	Conclusão
Rejeita	Não rejeita	Estacionária — diagnóstico firme
Não rejeita	Rejeita	Raiz unitária — diagnóstico firme
Rejeita	Rejeita	Possível tendência determinística
Não rejeita	Não rejeita	Amostra pouco informativa

3.4 Ordem de integração

Uma série é integrada de ordem d , denotada $I(d)$, quando requer d diferenciações para tornar-se estacionária. O aplicativo determina essa ordem testando diferenças sucessivas até obter rejeição.

Quebras estruturais. Testes de raiz unitária perdem poder na presença de mudanças abruptas de nível. Em séries brasileiras, a estabilização de 1994, a adoção do regime de metas em 1999 e a pandemia de 2020 constituem quebras relevantes. Uma série estacionária em torno de dois patamares distintos pode ser incorretamente classificada como $I(1)$.

4 Regressão linear

4.1 Especificação e estimação

$$y_t = \beta_0 + \beta_1 x_{1t} + \dots + \beta_k x_{kt} + \varepsilon_t$$

A estimação por mínimos quadrados ordinários é consistente sob condições relativamente fracas, mas a inferência — erros-padrão, testes de hipótese — depende de suposições adicionais frequentemente violadas em séries temporais.

4.2 Erros-padrão robustos

Os erros-padrão clássicos pressupõem homocedasticidade e ausência de autocorrelação. Em séries macroeconômicas, ambas as suposições costumam falhar: a volatilidade varia com o regime e os resíduos exibem persistência.

O estimador de Newey-West, denominado HAC por corrigir heterocedasticidade e autocorrelação, produz erros-padrão válidos sob essas violações. O aplicativo o adota como padrão. A escolha do número de defasagens envolve compromisso entre viés e variância; valores entre quatro e doze são usuais para dados mensais.

Consequência prática. Erros-padrão clássicos em presença de autocorrelação positiva subestimam sistematicamente a incerteza, inflando estatísticas t e produzindo significância ilusória. A correção HAC tipicamente amplia os intervalos de confiança.

4.3 Diagnósticos de resíduos

Teste	Hipótese nula	Interpretação da rejeição
Ljung-Box	Ausência de autocorrelação	Dinâmica não modelada; considere defasagens ou VAR
Jarque-Bera	Normalidade	Assimetria ou caudas pesadas; afeta inferência em amostra pequena
Breusch-Pagan	Homocedasticidade	Variância dependente dos regressores
Durbin-Watson	—	Valores próximos a 2 indicam ausência de autocorrelação de primeira ordem

Autocorrelação residual é o diagnóstico mais informativo. Sua presença indica que o modelo omite dinâmica relevante — a informação contida nos valores passados não foi plenamente extraída. A resposta adequada raramente é apenas corrigir os erros-padrão; é reespecificar o modelo.

4.4 Multicolinearidade

O fator de inflação da variância mede quanto a variância de um coeficiente é ampliada pela correlação com os demais regressores:

$$VIF_j = 1 / (1 - R_j^2)$$

R_j^2 é obtido regredindo o regressor j contra os demais. Valores superiores a 10 indicam colinearidade severa.

Colinearidade não enviesia os coeficientes, mas amplia seus erros-padrão a ponto de tornar a inferência individual pouco informativa. Os sinais podem inverter-se com pequenas alterações amostrais. As soluções são reduzir o conjunto de regressores, substituí-los por combinações interpretáveis como spreads, ou recorrer a regularização.

4.5 Validação fora da amostra

O coeficiente de determinação mede ajuste dentro da amostra e cresce mecanicamente com a inclusão de regressores. Não constitui evidência de capacidade preditiva.

O aplicativo implementa validação recursiva: estima o modelo com dados até determinado período, prevê o período seguinte, incorpora a observação realizada e repete. As métricas resultantes — raiz do erro quadrático médio, erro absoluto médio e viés — refletem desempenho preditivo genuíno, respeitando a ordenação temporal.

Sobre validação cruzada em séries temporais. A divisão aleatória convencional é inadequada: treinar com observações posteriores para prever anteriores constitui vazamento de informação futura. A validação deve sempre respeitar a ordem cronológica.

5 Cointegração

5.1 Conceito e intuição

Séries individualmente não-estacionárias podem apresentar combinação linear estacionária. Nesse caso, compartilham tendência estocástica comum e existe relação de equilíbrio de longo prazo entre elas.

$$y_t - \beta x_t = u_t, \text{ com } u_t \sim I(0)$$

Se o desvio da relação é estacionário, as variáveis não se afastam indefinidamente: forças econômicas as reconduzem ao equilíbrio.

A analogia usual é a de duas pessoas caminhando com um cão solto entre elas. Cada trajetória individual é errática e não-estacionária; a distância entre elas, porém, permanece limitada. A existência de cointegração implica que a regressão em nível não é espúria e que diferenciar ambas as séries eliminaria informação economicamente relevante.

5.2 Engle-Granger

O procedimento tem dois passos: estima-se a relação de longo prazo por MQO e testa-se a estacionariedade dos resíduos. Se estacionários, há cointegração. Os valores críticos diferem dos usuais, pois os resíduos são estimados, não observados.

A limitação é a natureza bivariada e a assimetria: o resultado pode variar conforme qual variável figure como dependente. Para sistemas com três ou mais variáveis, o procedimento de Johansen é preferível.

5.3 Johansen

O procedimento de Johansen aborda o problema em contexto multivariado, determinando o número de relações de cointegração — o posto r — por meio de duas estatísticas construídas a partir dos autovalores da matriz de longo prazo.

Estatística	Hipótese nula	Alternativa
Traço	No máximo r relações	Mais de r
Máximo autovalor	Exatamente r relações	Exatamente $r + 1$

A leitura é sequencial, do topo da tabela para baixo. Rejeitar a hipótese de posto zero indica ao menos uma relação; rejeitar a de posto unitário indica ao menos duas. O posto é o número de rejeições consecutivas.

Com n variáveis, o posto máximo é $n - 1$. Posto igual a n indicaria que todas as séries já são estacionárias, contradizendo a premissa do procedimento.

6 Modelos vetoriais

6.1 VAR: motivação

A crítica de Sims aos modelos macroeconômicos estruturais tradicionais apontava que suas restrições de identificação — quais variáveis são exógenas, quais coeficientes são nulos — careciam de fundamentação empírica e refletiam convenções não testadas. A proposta alternativa foi tratar todas as variáveis simetricamente, como endógenas.

$$\mathbf{y}_t = \mathbf{c} + \mathbf{A}_1 \mathbf{y}_{t-1} + \dots + \mathbf{A}_p \mathbf{y}_{t-p} + \mathbf{u}_t$$

Cada variável do vetor é função das defasagens de todas as variáveis do sistema, inclusive de si mesma.

Os coeficientes individuais de um VAR não admitem interpretação econômica direta: são numerosos e capturam efeitos indiretos entrelaçados. A análise apoia-se em três objetos derivados: funções de resposta a impulso, decomposição da variância e testes de causalidade de Granger.

6.2 Seleção de ordem

O número de defasagens é escolhido por critérios de informação, que penalizam a complexidade do modelo:

Critério	Característica	Uso recomendado
AIC	Penalização branda; tende a selecionar mais defasagens	Previsão
BIC	Penalização severa; consistente	Inferência estrutural
HQIC	Intermediário	Uso geral

Em amostras curtas, a divergência entre AIC e BIC é comum. A recomendação prática é privilegiar a parcimônia: modelos com menos parâmetros são mais estáveis e menos suscetíveis a sobreajuste.

6.3 Funções de resposta a impulso

A função de resposta a impulso traça o efeito dinâmico de um choque de um desvio-padrão em uma variável sobre a trajetória de todas as demais ao longo do horizonte considerado.

A leitura observa três dimensões: o sinal do efeito, sua magnitude e sua persistência. Uma resposta que cruza o eixo zero e retorna indica efeito transitório; uma que se mantém deslocada indica efeito duradouro.

Padrão esperado na transmissão monetária. Um choque contracionista de juros tipicamente reduz o crédito em dois a seis meses, desacelera a atividade em seis a doze meses e afeta a inflação em nove a dezoito meses. Essa estrutura de defasagens crescentes é a assinatura empírica do mecanismo de transmissão.

6.4 Identificação estrutural

Os resíduos do VAR em forma reduzida são correlacionados entre equações, o que impede interpretá-los como choques econômicos independentes. A identificação requer restrições adicionais.

A decomposição de Cholesky impõe estrutura recursiva: a primeira variável na ordenação não responde contemporaneamente a nenhuma outra; a segunda responde apenas à primeira; e assim sucessivamente. A ordenação deve refletir a velocidade de ajuste — variáveis mais lentas primeiro.

Sensibilidade à ordenação. Os resultados dependem da ordem escolhida. Verificar a robustez a ordenações alternativas é procedimento obrigatório: se as conclusões se alteram substancialmente, a identificação é frágil e as respostas a impulso não sustentam interpretação estrutural.

Uma anomalia recorrente é o *price puzzle*: elevação da inflação após choque contracionista de juros. A explicação usual é omissão de variável antecipatória — a autoridade monetária eleva juros porque antecipa pressão inflacionária que o modelo não observa. A correção convencional inclui índices de preços de commodities ou expectativas no sistema.

6.5 Decomposição da variância

A decomposição da variância do erro de previsão quantifica a fração da incerteza sobre cada variável atribuível a cada choque, em cada horizonte.

No horizonte imediato, a própria variável domina. À medida que o horizonte se amplia, choques de outras variáveis ganham participação. Um choque que explique parcela reduzida da variância de outra variável tem, empiricamente, papel modesto na determinação de suas flutuações — resultado substantivo, não deficiência do modelo.

6.6 Causalidade de Granger

O teste avalia se as defasagens de uma variável melhoram a previsão de outra além do que suas próprias defasagens já proporcionam.

Advertência conceitual. Causalidade de Granger é precedência temporal preditiva, não causalidade estrutural. Duas variáveis podem exibir relação de Granger por responderem a um terceiro fator omitido, ou porque uma antecipa a outra sem determiná-la. A denominação é infeliz e induz a sobreinterpretação frequente.

6.7 VECM

Quando as séries são $I(1)$ e cointegradas, o VAR em diferenças descarta a informação de longo prazo. O modelo vetorial de correção de erros incorpora explicitamente o mecanismo de retorno ao equilíbrio:

$$\Delta \mathbf{y}_t = \alpha \boldsymbol{\beta}' \mathbf{y}_{t-1} + \sum_{i=1}^{k-1} \boldsymbol{\Gamma}_i \Delta \mathbf{y}_{t-i} + \boldsymbol{\varepsilon}_t$$

$\boldsymbol{\beta}$ define a relação de longo prazo; α mede a velocidade de ajuste ao desequilíbrio; $\boldsymbol{\Gamma}$ captura a dinâmica de curto prazo.

O vetor α concentra a interpretação econômica mais rica do modelo. Um coeficiente negativo e significativo indica que a variável responde ao desequilíbrio, corrigindo-o. Sua magnitude expressa a fração do desvio eliminada a cada período — um valor de $-0,05$ implica correção de cinco por cento ao mês, com meia-vida aproximada de catorze meses.

Coeficiente de ajuste estatisticamente indistinguível de zero caracteriza exogeneidade fraca: a variável influencia o sistema sem responder a ele. Identificar qual variável se ajusta e qual permanece exógena é frequentemente a conclusão substantiva mais relevante da análise.

7 Modelos de resposta binária

7.1 Probit e Logit

Quando a variável dependente assume apenas dois valores, o modelo linear é inadequado: produz previsões fora do intervalo unitário e resíduos necessariamente heterocedásticos. Os modelos Probit e Logit resolvem essa limitação por meio de uma função de ligação:

$$P(y_t = 1 \mid X_t) = F(X_t'\beta)$$

F é a distribuição acumulada da normal padrão no Probit, ou a função logística no Logit. Ambas são monotônicas e limitadas ao intervalo [0,1].

Os dois modelos produzem resultados qualitativamente semelhantes. A escolha entre eles é, na prática, convencional.

7.2 Previsão de recessão

A aplicação macroeconômica canônica define a variável dependente como indicador de recessão h períodos à frente, prevista com informação disponível no período corrente.

A inclinação da curva de juros é o preditor mais consistentemente documentado nessa literatura. A interpretação econômica combina expectativas de política monetária futura e prêmio de prazo: achatamento ou inversão sinaliza expectativa de afrouxamento futuro, condizente com antecipação de desaceleração.

7.3 Avaliação por AUC

Modelos binários não admitem coeficiente de determinação convencional. A avaliação apoia-se na área sob a curva ROC, que mede a capacidade de discriminação entre observações com e sem o evento.

AUC	Interpretação
0,50	Equivalente a classificação aleatória
0,70 - 0,80	Discriminação aceitável
0,80 - 0,90	Discriminação boa
> 0,90	Excelente — verificar sobreajuste em amostras pequenas

Os coeficientes estimados admitem interpretação de sinal, mas não de magnitude: referem-se ao índice latente, não à probabilidade. Os efeitos marginais, calculados pelo aplicativo, traduzem os coeficientes em variação de probabilidade por unidade do regressor.

Escassez de eventos. A limitação central desses modelos em aplicações macroeconômicas é o número reduzido de recessões observadas. Uma amostra que contenha dois ou três episódios oferece base frágil para estimação: o modelo tende a memorizá-los, exibindo desempenho excelente dentro da amostra e capacidade preditiva reduzida fora dela.

8 Regularização

8.1 Motivação

Quando o número de regressores é elevado relativamente ao de observações, ou quando há colinearidade acentuada, a estimação por MQO torna-se instável: os coeficientes exibem variância alta e alteram-se substancialmente com pequenas perturbações amostrais.

A regularização introduz penalização sobre a magnitude dos coeficientes, aceitando viés em troca de redução de variância. O resultado é frequentemente melhor desempenho preditivo, ainda que os estimadores deixem de ser não-viesados.

8.2 LASSO, Ridge e Elastic Net

$$\min_{\beta} (1/2n)\|y - X\beta\|^2 + \lambda[\rho\|\beta\|_1 + ((1-\rho)/2)\|\beta\|^2]$$

λ controla a intensidade da penalização; ρ define a composição entre as normas. $\rho = 1$ corresponde ao LASSO, $\rho = 0$ ao Ridge.

Método	Penalização	Comportamento
LASSO	Norma L1	Anula coeficientes; realiza seleção de variáveis
Ridge	Norma L2	Contraí coeficientes sem anulá-los
Elastic Net	Combinação	Seleciona grupos correlacionados conjuntamente

A padronização das variáveis é requisito, não opção. A penalização incide sobre a magnitude dos coeficientes, que depende da escala das variáveis: regressores medidos em unidades distintas seriam penalizados de forma arbitrariamente desigual.

8.3 Colinearidade e instabilidade

O comportamento do LASSO sob colinearidade merece atenção particular. Diante de um grupo de regressores altamente correlacionados, o método tende a selecionar um deles e anular os demais — e a escolha específica é instável, alterando-se com pequenas variações amostrais ou no parâmetro de penalização.

Implicação para teste de hipóteses. A não-seleção de uma variável não constitui evidência de irrelevância: sua informação pode ter sido absorvida por outra do mesmo grupo. Concluir que a inclinação da curva de juros "não importa" porque o LASSO reteve um vértice específico e a descartou seria inferência incorreta.

O Elastic Net atenua essa instabilidade. O componente L2 induz seleção conjunta de variáveis correlacionadas, produzindo resultados substancialmente mais estáveis. Para dados macroeconômicos e financeiros, caracterizados por colinearidade elevada, constitui a escolha preferível.

8.4 Stability selection

O procedimento consiste em reestimar o modelo em múltiplas subamostras aleatórias e registrar a frequência com que cada variável é selecionada. Variáveis consistentemente escolhidas — convencionalmente acima de sessenta por cento das reamostragens — oferecem base mais confiável que uma seleção única.

O procedimento é particularmente valioso quando a seleção será interpretada substantivamente. Uma variável retida em ajuste único mas com frequência baixa foi provavelmente selecionada por acaso amostral.

8.5 Limites interpretativos

Natureza do método. LASSO e Elastic Net são procedimentos de predição e seleção, não de inferência causal. Uma variável selecionada prediz bem; isso não estabelece relação causal. Os erros-padrão convencionais não são válidos após seleção, pois esta é ela própria função dos dados — problema conhecido como inferência pós-seleção.

9 Modelos macroeconômicos aplicáveis

Esta seção apresenta especificações concretas construíveis com o aplicativo, indicando variáveis, transformações e interpretação esperada.

9.1 Transmissão de política monetária

Estrutura: VAR estrutural com quatro variáveis.

Posição	Variável	Transformação
1	Atividade (PIB)	Log-diferença
2	Inflação	Nível (já é taxa)
3	Taxa básica de juros	Primeira diferença
4	Crédito	Log-diferença

A ordenação reflete a hipótese de que a atividade real responde com defasagem a condições financeiras, enquanto variáveis financeiras incorporam informação contemporânea. A análise concentra-se nas respostas a impulso do choque de juros e na decomposição da variância da atividade.

9.2 Curva de Phillips

$$\pi_t = \alpha + \beta \cdot u_t + \gamma \cdot E_t[\pi_{t+1}] + \varepsilon_t$$

A versão com expectativas corresponde à formulação novo-keynesiana. O coeficiente do desemprego mede o custo de desinflação em termos de atividade; o das expectativas mede o grau de ancoragem. Valor de γ próximo à unidade indica expectativas plenamente incorporadas; valores inferiores sugerem inércia inflacionária relevante.

9.3 Regra de Taylor

$$i_t = \rho \cdot i_{t-1} + (1-\rho)[\alpha + \varphi_\pi(\pi_t - \pi^*) + \varphi_y \tilde{y}_t]$$

O termo defasado captura suavização da taxa de juros, comportamento documentado empiricamente em bancos centrais.

O princípio de Taylor estabelece que φ_π deve exceder a unidade para que a política estabilize a inflação: a resposta nominal precisa superar a variação inflacionária para elevar o juro real. Coeficiente inferior a um caracteriza política acomodatória.

9.4 Ciclos de crédito

Estrutura: teste de cointegração seguido de VECM entre logaritmos de produto e crédito.

A hipótese subjacente é a existência de relação estável de longo prazo entre crédito e atividade, com desvios corrigidos gradualmente. O interesse recai sobre os coeficientes de ajuste: identificar qual variável retorna ao equilíbrio informa sobre a direção predominante do mecanismo.

9.5 Previsão de recessão

Estrutura: Probit com horizonte de seis a doze meses.

Preditor central é a inclinação da curva de juros; complementos naturais incluem expansão do crédito e variação do

desemprego. A avaliação deve necessariamente incluir validação em período reservado, dada a escassez de eventos.

Contraponto metodológico. Um modelo de previsão de recessão deve ser comparado a referências simples — a inclinação da curva isoladamente, ou um modelo autorregressivo. Especificações elaboradas que não superam essas referências não justificam sua complexidade.

10 Arquitetura do código

10.1 Separação em camadas

O aplicativo distribui-se em quatro módulos com responsabilidades distintas. A separação não é organizacional apenas: permite testar a lógica econométrica independentemente da interface, e alterar a apresentação sem risco de introduzir erros nos cálculos.

Módulo	Responsabilidade	Depende de
<code>core.py</code>	Carregamento e transformações	pandas, numpy
<code>modelos.py</code>	Estimação e testes	statsmodels, scikit-learn
<code>manual.py</code>	Documentação interativa	streamlit
<code>app.py</code>	Interface e orquestração	todos os anteriores

A dependência é unidirecional: `app.py` importa os demais, mas nenhum módulo de cálculo importa a interface. Consequência prática relevante é que `modelos.py` pode ser utilizado em scripts convencionais, independentemente do aplicativo.

10.2 core.py — dados e transformações

Concentra o carregamento de arquivos e a aplicação de transformações. O carregamento identifica a coluna temporal, converte para índice datetime e força tipagem numérica nas demais colunas.

As transformações são implementadas como função única com despacho por parâmetro. A alternativa — uma função por transformação — exigiria alteração em múltiplos pontos a cada inclusão. Com o desenho adotado, acrescentar uma transformação requer uma cláusula na função e uma entrada no dicionário de rótulos, e a interface a exibe automaticamente.

```
TRANSFORMACOES = {
    "logdiff": "Log-diferença (≈ variação % mensal)",
    "hp_ciclo": "Ciclo Hodrick-Prescott",
    ...
}

def aplicar_transformacao(s, tipo, lamb_hp=14400):
    if tipo == "logdiff":
        return np.log(s.where(s > 0)).diff() * 100
    ...
```

A construção `s.where(s > 0)` merece nota: converte valores não-positivos em ausentes antes do logaritmo, evitando propagação de valores indefinidos. Séries que assumem valores negativos — variações percentuais, por exemplo — não admitem transformação logarítmica, e a implementação torna essa restrição explícita em vez de produzir resultado silenciosamente incorreto.

A função `amostra_comum` centraliza o recorte temporal e a remoção de observações incompletas. Sua existência garante que todos os modelos operem sobre a mesma definição de amostra efetiva.

10.3 modelos.py — motor econométrico

Reúne as rotinas de estimação e teste, organizadas em oito seções temáticas. Três decisões de projeto orientam sua implementação.

Retorno estruturado com interpretação

As funções de teste não devolvem apenas estatísticas, mas dicionários contendo também valores críticos e conclusão textual. A interpretação é codificada uma vez, no módulo de cálculo, e não replicada em cada ponto de exibição.

```

return {
    "estatistica": r[0],
    "p_valor": r[1],
    "crit_5%": r[4]["5%"],
    "conclusao": "Estacionária (rejeita H0)" if r[1] < 0.05
                else "Não-estacionária (não rejeita H0)",
}

```

Diagnóstico cruzado explícito

A função `diagnostico_conjunto` combina os resultados de ADF e KPSS nas quatro configurações possíveis. A alternativa seria deixar a interpretação a cargo do usuário — decisão que produziria erro sistemático, dado que a inversão das hipóteses nulas é fonte reconhecida de confusão.

Formato longo para visualização

As funções de resposta a impulso e decomposição da variância convertem os arranjos tridimensionais produzidos pelo statsmodels em tabelas de formato longo, com colunas identificando horizonte, choque e resposta. O formato longo é o esperado pelas bibliotecas de visualização e simplifica a construção de painéis comparativos.

```

for h in range(arr.shape[0]):
    for i, choque in enumerate(nomes):
        for j, resposta in enumerate(nomes):
            reg.append({"horizonte": h, "choque": choque,
                      "resposta": resposta, "valor": arr[h, j, i]})

```

A indexação `arr[h, j, i]` — com resposta antes de choque — reflete a convenção do statsmodels e é ponto de erro frequente na leitura desses resultados.

Validação cruzada temporal

A regularização emprega `TimeSeriesSplit` em vez de particionamento aleatório. A distinção é substantiva: a validação convencional treina o modelo com observações posteriores para prever anteriores, incorporando informação futura e produzindo estimativa otimista do desempenho.

10.4 app.py — interface e orquestração

Organiza a aplicação em dez abas e gerencia o estado da sessão. Três aspectos merecem descrição.

Estado e composição de bases

As transformações criadas pelo usuário são mantidas em estrutura separada da base original. A função `base_ativa` compõe ambas quando requisitado.

```

def base_ativa():
    if st.session_state.df_trans is None or st.session_state.df_trans.empty:
        return st.session_state.df
    return st.session_state.df.join(st.session_state.df_trans, how="left")

```

A separação preserva a integridade dos dados originais: transformações podem ser removidas sem risco de alterar a base carregada, e a origem de cada variável permanece rastreável.

Encadeamento explícito no VAR

A estimação do VAR divide-se em três ações sequenciais — seleção de ordem, escolha de defasagens, estimação — em vez de execução única. O desenho reflete a prática correta: a ordem deve ser examinada antes de fixada, e a inspeção dos critérios de informação é parte da análise, não etapa automatizável.

Documentação junto ao resultado

Cada aba apresenta a equação de referência antes dos controles e notas de interpretação após os resultados. A alternativa — concentrar toda documentação em seção apartada — separaria a explicação do momento em que é necessária.

10.5 manual.py — documentação interativa

Isolado como módulo próprio por conter exclusivamente conteúdo textual extenso. Mantê-lo em `app.py` dificultaria a leitura da lógica de interface. A separação permite ampliar a documentação sem alterar o código funcional.

10.6 Decisões de projeto

Decisão	Justificativa
Erros HAC como padrão	Autocorrelação é a norma em séries temporais; o padrão deve ser a opção segura
Interpolação não extrapola	Preencher além dos dados observados fabricaria informação inexistente
Verificação automática de estabilidade	VAR instável invalida as respostas a impulso; a verificação não deve ser opcional
Elastic Net como padrão	Estabilidade superior sob colinearidade, característica dominante em dados macrofinanceiros
Alertas quando nenhuma variável é selecionada	Resultado válido, porém contraintuitivo; requer explicação explícita
Estatísticas de cobertura em destaque	O gargalo amostral condiciona todas as escolhas subsequentes

11 Limitações e extensões

Limitações reconhecidas

Ausência de bandas de confiança nas respostas a impulso. As funções são apresentadas como estimativas pontuais. A construção de intervalos por bootstrap é computacionalmente onerosa e foi omitida; a avaliação da significância requer, no momento, uso direto do statsmodels.

Identificação limitada a esquema recursivo. A decomposição de Cholesky é a única forma de identificação implementada. Esquemas alternativos — restrições de sinal, restrições de longo prazo — não estão disponíveis.

Ausência de tratamento de quebras estruturais. Testes com quebra endógena não foram incluídos. O recorte temporal por regime é feito manualmente pelo usuário.

Modelos univariados não contemplados. ARIMA e SARIMAX, úteis como referência de previsão, não foram implementados.

Extensões naturais

A arquitetura modular facilita ampliações. Acrescentar um modelo requer adicionar função em `modelos.py` e aba correspondente em `app.py`, sem alteração dos componentes existentes.

Extensão	Aplicação
ARIMA / SARIMAX	Referência de previsão univariada
Modelos de mudança de regime	Datação endógena de ciclos
VAR bayesiano	Sistemas maiores em amostras curtas
Modelos de frequência mista	Combinar séries mensais e trimestrais sem interpolação
Testes de quebra estrutural	Identificação endógena de mudanças de regime
Exportação de resultados	Geração de tabelas formatadas para publicação

Observação final. A utilidade de um laboratório dessa natureza reside menos na quantidade de modelos disponíveis que na disciplina que impõe ao processo analítico. Testar estacionariedade antes de estimar, verificar estabilidade antes de interpretar respostas a impulso, validar fora da amostra antes de afirmar capacidade preditiva — essas práticas distinguem análise confiável de exercício de ajuste de curvas. A ferramenta as torna imediatas o suficiente para que sejam efetivamente observadas.